

„Podstawy Sztucznej Inteligencji”

Scenariusz 4

Temat ćwiczenia: *Uczenie sieci regułą Hebba.*

1. Model neuronu Hebba – zmiana wagi w_{ij} neuronu odbywa się proporcjonalnie do iloczynu jego sygnału wejściowego oraz wyjściowego:


$$\Delta w_{ij} = \eta y_j y_i$$

gdzie η jest stałą uczenia z przedziału $(0,1)$. Reguła Hebba może być stosowana do różnego typu struktur sieci neuronowych i różnych funkcji aktywacji zastosowanych w modelu neuronu. Reguła Hebba jest praktyczną realizacją stwierdzenia z zakresu neurobiologii:

„Jeżeli akson komórki A bierze systematycznie udział w pobudzeniu komórki B powodującym jej aktywację, to wywołuje to zmianę metaboliczną w jednej lub obu komórkach, prowadzącą do wzrostu skuteczności pobudzania B przez A”.

Uczenie neuronu z zastosowaniem reguły Hebba może się odbywać w trybie bez nauczyciela lub z nauczycielem. W pierwszym przypadku używa się aktualnej wartości y_i sygnału wyjściowego neuronu. W uczeniu z nauczycielem wartość sygnału wyjściowego y_i zastępuje się wartością zadana d_i dla tego neuronu. Regułę Hebba można wówczas zapisać w postaci:

$$\Delta w_{ij} = \eta y_j d_i$$



Rys. 2.13. Ogólny model neuronu Hebba

2. Listing programu

```
1 - close all; clear all; clc;
2
3 - PR=[0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
4       0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
5       0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
6       0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
7       0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
8       0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
9       0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1;
10      0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1; 0 1];
11 %wejścia do sieci i min/max wartości wejść
12 S=64; %ilość neuronów na wyjściu
13 net = newff(PR,S,{'tansig'},'trainlm','learnh');
14
15
16 %wejście
17 WE=[0 0 0 0
18      0 0 0 0
19      1 1 0 1
20      1 1 0 1
21      1 1 0 1
22      1 1 0 1
23      0 0 0 0
24      0 0 0 0
25      0 0 0 0
26      1 1 0 1
27      0 0 1 0
28      0 0 0 0
29      0 0 0 0
30      0 0 1 0
31      1 1 0 1
32      0 0 0 0
33      1 1 0 1
34      0 0 0 0
35      1 1 1 1
36      0 0 0 0
37      0 0 0 0
38      1 1 1 1
39      0 0 0 0
40      1 1 0 1
41      1 1 0 1
42      0 0 0 0
43      0 0 0 0
44      0 0 0 0
45      0 0 0 0
46      0 0 0 0
47      0 0 0 0
48      1 1 0 1
49      1 1 0 1
50      0 0 0 0
51      1 0 0 0
52      0 1 0 1
53      0 1 0 1
54      1 0 1 0
55      0 0 0 0
56      1 1 0 1
57      1 1 0 1
58      0 0 0 0
59      0 0 0 1
60      1 1 1 0
61      1 1 1 0
62      0 0 0 1
63      0 0 0 0
64      1 1 0 1
65      0 0 0 0
```

```

65         0 0 0 0
66         1 1 0 1
67         0 0 0 0
68         0 0 0 0
69         0 0 0 0
70         0 0 1 0
71         1 1 0 1
72         0 0 0 0
73         0 0 0 0
74         0 0 0 0
75         1 1 0 1
76         1 1 0 1
77         1 1 0 1
78         1 1 0 1
79         0 0 0 0
80         0 0 0 0
81     ];
82     %Wyjście
83 -   WY=[1 0 0 0 %usmiech
84         0 1 0 0 %szok
85         0 0 1 0 %pocalunek
86         0 0 0 0]; %smutek
87
88 -   lp.dr = 0.5; %wsp zapominania
89 -   lp.lr = 0.9; %wsp uczenia
90 -   hebRule=learnh([],WE,[],[],WY,[],[],[],[],[],lp,[]);
91 -   heb=hebRule';
92
93 -   net.trainParam.epochs = 1000; %ilosc epok
94 -   net.trainParam.goal = 0.001; %Cel wydajności
95 -   net.trainParam.lr=0.5; % wskaźnik uczenia sie
96 -   net=train(net, WE, heb); %trenowanie
97   %emotikony
98 -   usmiech = [0 0 1 1 1 1 0 0;
99               0 1 0 0 0 0 1 0;
100              1 0 1 0 0 1 0 1;
101              1 0 0 0 0 0 0 1;
102              1 0 1 0 0 1 0 1;
103              1 0 0 1 1 0 0 1;
104              0 1 0 0 0 0 1 0;
105              0 0 1 1 1 1 0 0];
106
107 -   szok = [0 0 1 1 1 1 0 0;
108            0 1 0 0 0 0 1 0;
109            1 0 1 0 0 1 0 1;
110            1 0 0 0 0 0 0 1;
111            1 0 0 1 1 0 0 1;
112            1 0 0 1 1 0 0 1;
113            0 1 0 0 0 0 1 0;
114            0 0 1 1 1 1 0 0];
115
116 -   pocalunek = [0 0 0 0 0 0 0 0;
117                 0 0 1 0 0 1 0 0;
118                 0 0 1 0 0 1 0 0;
119                 0 0 0 0 0 0 0 0;
120                 0 0 0 0 0 1 0 0;
121                 0 0 0 1 1 0 0 0;
122                 0 0 0 0 0 1 0 0;
123                 0 0 0 0 0 0 0 0];
124

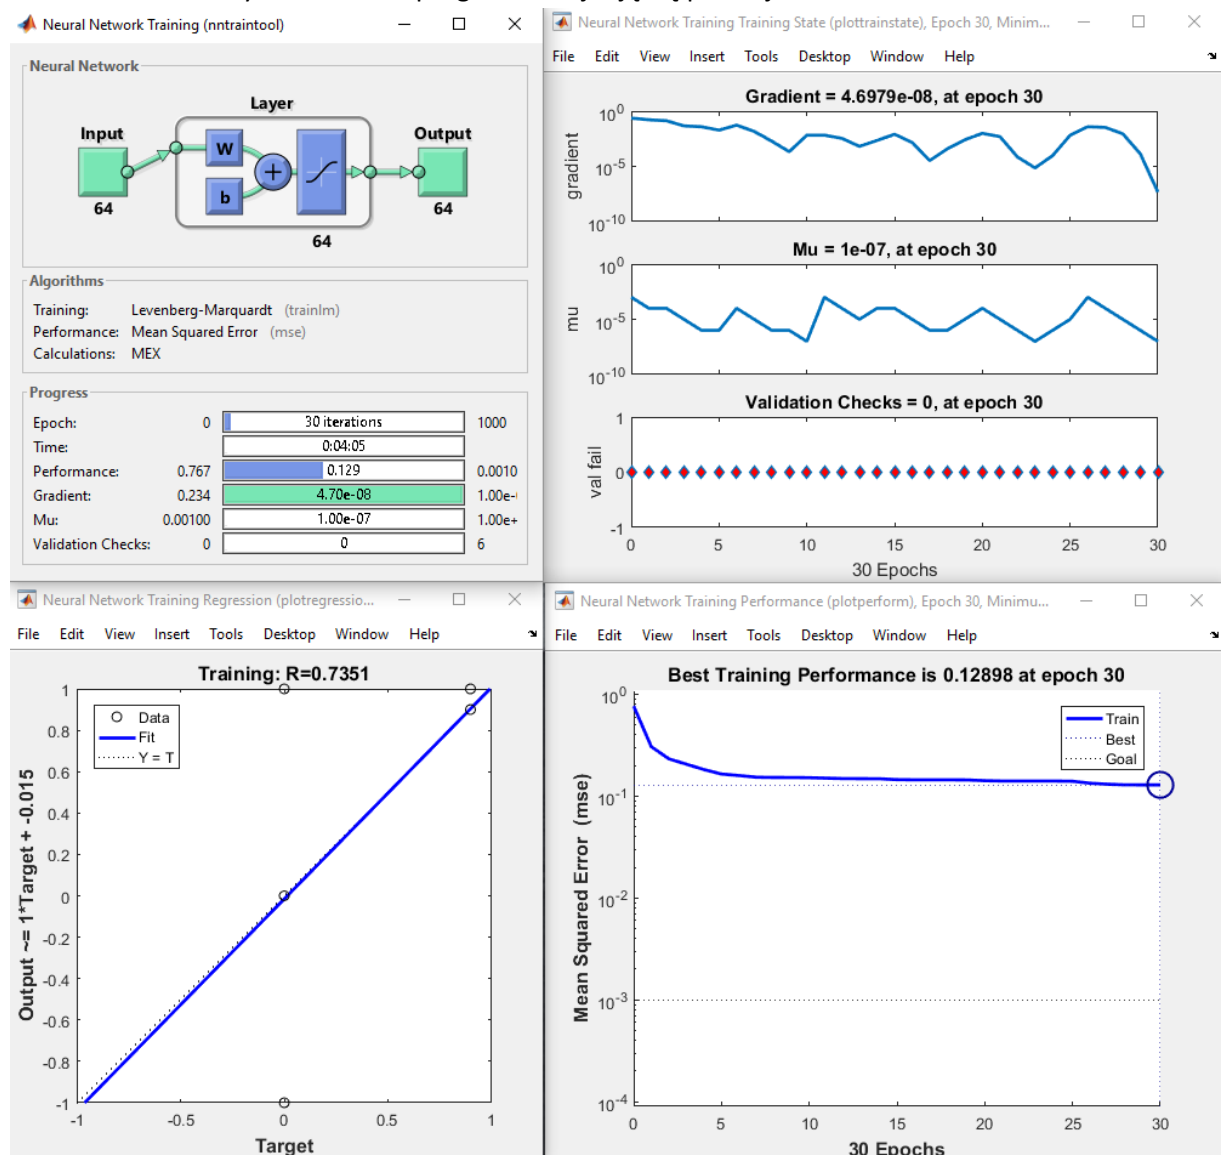
```

```

124
125 -     smutek = [0 0 1 1 1 1 0 0;
126               0 1 0 0 0 0 1 0;
127               1 0 1 0 0 1 0 1;
128               1 0 0 0 0 0 0 1;
129               1 0 0 1 1 0 0 1;
130               1 0 1 0 0 1 0 1;
131               0 1 0 0 0 0 1 0;
132               0 0 1 1 1 1 0 0];
133
134
135 -     efekt1=sim(net, testa);%symulacja
136 -     efekt=Hebb;
137
138 -     disp('Hebb:')
139 -     disp('Usmiech'),disp(sum(efekt(1,':')));
140 -     disp('Szok'),disp(sum(efekt(2,':')));
141 -     disp('Pocalunek'),disp(sum(efekt(3,':')));
142 -     disp('Smutek'),disp(sum(efekt(4,':')));

```

3. Wygenerowane zostały dane uczące i testujące zawierające 4 różne czarno białe emotikony. Kolejnym krokiem było uczenie sieci dla różnych współczynników uczenia i zapominania oraz testowanie sieci. Wyniki działania programu znajdują się poniżej.



4. Wnioski

- Reguła Hebba jest wolniejsza od uczenia z nauczycielem.
- Duży wpływ ma dobór początkowych wartości wag neuronów.
- Reguła Hebba pozwala na uczenie sieci bez nauczyciela.